

# 基于改进 YOLOv11n 的减震铝筒识别算法

刘书乐,方成刚,杨浩杰

(南京工业大学机械与动力工程学院,南京 211800)

**摘要:**分拣机器人在不稳定光照、工件相似度高和图像模糊等复杂的工业环境下识别减震铝筒时,检测模型难以捕捉关键特征,导致分拣的准确性较低。针对上述问题,提出基于 YOLOv11n 模型的针对特殊工况下的减震铝筒目标检测的改进算法。首先,针对工件相似度高问题,设计了边缘与空间信息整合模块(edge and spatial information integration module, ESIIM)作为网络的前端模块,能够更加全面地刻画减震铝筒图像内容;其次,引入全维度动态卷积 ODConv 对基础模型中的 C3K2 内部进行重构,通过多维度注意力机制优化特征选择过程;再次,在 Neck 部分加入 CGAFusion 模块融合来自不同层的特征图,增强特征的表示能力,减小误检率;最后,加入动态上采样器 DySample 采样方法,在保持高效率的同时,提升了处理质量。试验结果表明,该模型在自制数据集下的 mAP@0.5:0.95 达到了 90.3%,较基准模型提升了 4.1%。同时,减震铝筒的错检率降低了 5.53%。满足分拣机器人对减震铝筒精准识别的要求。

**关键词:**目标检测;YOLOv11n;减震铝筒;特征提取

**中图分类号:**TH165;TG659

**文献标识码:**A

## Identification Algorithm for Shock-Absorbing Aluminum Cylinder Based on Improved YOLOv11n

LIU Shule, FANG Chenggang, YANG Haojie

(School of Mechanical and Power Engineering, Nanjing Tech University, Nanjing 211800, China)

**Abstract:** When sorting robots recognize shock-absorbing aluminum tubes in complex industrial environments such as unstable lighting, high workpiece similarity, and blurry images, the detection model is difficult to capture key features, resulting in low sorting accuracy. Propose an improved algorithm for target detection of shock-absorbing aluminum cylinders under special working conditions based on the YOLOv11n model. Firstly, to address the issue of high similarity between workpieces, an ESIIM edge and spatial information integration module was designed as the front-end module of the network, which can more comprehensively depict the image content of shock-absorbing aluminum tubes. Secondly, the full dimensional dynamic convolution ODConv is introduced to reconstruct the internal structure of C3K2 in the base model, and the feature selection process is optimized through a multidimensional attention mechanism. Add CGA-Fusion module to the Neck section to fuse feature maps from different layers, enhance feature representation ability, and reduce missed detection rates. Finally, the dynamic upsampler DySample sampling method was added to improve processing quality while maintaining high efficiency. The experimental results indicate that the model mAP@0.5:0.95 has reached 90.3% under the self-made dataset, which is higher than the benchmark model has increased by 4.1%. At the same time, the false detection rate of shock-absorbing aluminum tubes has been reduced by 5.53%. Satisfy the precise identification of shock-absorbing aluminum tubes by sorting robots.

**Keywords:** object detection; YOLOv11n; shock-absorbing aluminum cylinder; feature extraction

## 0 引言

我国摩托车、电动车产销量同比、环比皆出现增长,外贸出口继续保持增长态势。其中电动车的减震

铝筒作为前轮的减震系统主要部件产量连年提高,减震铝筒的种类随着电动车的种类的增加而增加。目前某工厂还是依靠人工的方式对减震铝筒进行分拣。但

收稿日期:2025-02-19;修回日期:2025-04-14

作者简介:刘书乐(2000—),男,硕士研究生,研究方向为机器视觉,(E-mail)1377152822@qq.com;通信作者:方成刚(1974—),男,教授,研究方向为智能制造,机器视觉等,(E-mail)2488@njtech.edu.cn。

引用本文:刘书乐,方成刚,杨浩杰.基于改进 YOLOv11n 的减震铝筒识别算法[J].组合机床与自动化加工技术,2026(1):41-46.

LIU Shule, FANG Chenggang, YANG Haojie. Identification algorithm for shock-absorbing aluminum cylinder based on improved YOLOv11n [J]. Modular Machine Tool & Automatic Manufacturing Technique, 2026(1):41-46.

是由于不同类型的减震铝筒相似度非常高,且车间光照不稳定,所以人工分拣不仅效率低,漏检率还高。因此,使用机器人分拣对工厂实现智能化升级就显得尤为重要,而目标检测是机器人抓取减震铝筒的前置任务。

目前,目标检测模型主要分为单阶段算法和两阶段算法,两阶段算法的主要原理是提取一组对象的候选框,再对候选框内的区域进行分类判别,从而实现目标检测,例如:RCNN<sup>[1]</sup>、Fast-RCNN<sup>[2]</sup>、Faster-RCNN<sup>[3]</sup>和 Mask-RCNN<sup>[4]</sup>等,大量重叠候选框上的冗余特征计算导致检测速度极慢,所以并不满足高速的产线需求。单阶段算法如 YOLO<sup>[5-8]</sup> 系列,由于 YOLO 速度快满足基本的工业需求,所以受到大量研究者的青睐。程光耀等<sup>[9]</sup>采用了 Focal Loss 损失函数和分组混洗卷积模块改进 YOLOv5s 模型,解决了基础模型在检测齿轮箱螺丝性能不足的问题。朱晓彤等<sup>[10]</sup>使用 LigFPN 加强特征融合网络改进 YOLOv5n,解决了基础模型在光线不稳定的场景下存在误检和漏检的问题。季星宇等<sup>[11]</sup>设计使用 DBB-GC 来增强在特征提取时的空间感知能力,提升目标复合特征的质量。WANG 等<sup>[12]</sup>利用改进的 EfficientNetv2 网络替换 YOLOv11 原有主干网络,提高了复杂海况下对不同种类舰船的特征学习能力。李彬等<sup>[13]</sup>引入 CSPOK 模块和 ContextGuided-Block\_Down 卷积,显著提升了全局特征的提取能力和多尺度特征的融合能力。

本文针对减震铝筒在分类任务中,不同减震铝筒相似度高难以检测和工厂环境复杂多变的情况,提出了改进型的 YOLOv11n 的模型,设计了边缘与空间信息整合模块 (edge and spatial information integration module, ESIIM) 作为网络前端,刻画减震铝筒图像内容。引入全维度动态卷积 ODConv 重构基础模型 C3K2 内部,通过多维度注意力机制优化特征选择。在 Neck 部分加入 CGAFusion 模块融合不同层特征图,增强特征表示能力。最后加入动态上采样器 DySample,在保持高效率的同时提升处理质量。

## 1 YOLOv11 目标检测算法

YOLOv11 网络的结构如图 1 所示。




图 1 YOLOv11 的网络结构图

YOLOv11 是根据 YOLOv8 改进而来,第一个改进

是将 YOLOv8 的特征提取模块 C2f 改成 C3k2, C3k2 是基于 C3 模块设计,通过可变卷积核和通道分离策略,使模型能够更好地捕捉广泛的上下文信息,在处理复杂场景时能显著提高特征提取的精度。第二个改进是在主干网络的最后加入 C2PSA,它结合了 PSA (point-wise spatial attention) 点空间注意力块,PSA 模块由于其独特的 SE 注意力机制,能够捕捉到更加丰富的特征信息,使其能够学习到更加复杂的非线性关系。第三个改进是在分类检测头中插入两个 DWConv (depth-wise convolution) 深度卷积,与标准卷积的区别就在于深度卷积的卷积核是单通道模式,需要对输入的每一个通道进行卷积,就会得到和输入特征图通道数一致的输出特征图,这样就可以降低计算量。

总而言之,YOLOv11 标志着目标检测技术的重大飞跃,在之前版本的 YOLO 基础上结合了新颖的架构元素,增强了其检测和分析对象的能力,其速度和效率相较于前代产品有了显著提升,这一最新的迭代在各种视觉任务中展示了非凡的多功能性<sup>[14]</sup>。

但是,YOLOv11 在本文的目标检测任务中,无法在复杂的车间环境下稳定识别不同类型的减震铝筒。

## 2 YOLOv11n 改进

如图 2 所示,在实际生产中,存在目标相似度高、光照不稳定和图像模糊的问题。



图 2 减震铝筒常见工况

针对上述问题,在主干网络的前端加入 ESIIM,加强图像中减震铝筒边缘轮廓信息的丰富程度;其次在 C3k2 中加入 ODConv 细化减震铝筒局部特征;然后将颈部网络中的上采样层替换成 DySample 动态上采样法,减少一定的计算量;最后,在检测头前面加入 CGA-Fusion,将网络中的低级特征与相应的高级特征有效地融合。改进后的网络结构图如图 3 所示。




图 3 改进型 YOLOv11 网络结构图

## 2.1 ESIIM 边缘与空间信息整合模块

由于不同的减震铝筒之间轮廓不同,所以提取目标图像轮廓信息有助于解决不同目标之间特征相似度高问题,本文在输入和主干网络之间加入边缘提取模块,让网络充分接受减震铝筒的边缘信息。郭宏等<sup>[15]</sup>提出了 EIFM 边缘信息融合模块有效地提取出了图中的边缘信息,但是提取边缘时没有进行下采样的操作,且与输入直接融合,这无疑增大了数据规模与计算量。基于这一思路,设计了一种名为 ESIIM 的新型模块,如图 4 所示。

ESIIM 模块先用  $3 \times 3$  的卷积核以 2 的步长进行二倍的下采样操作,然后分为两路分支,一路分支经过边缘提取卷积 SobelConv 提取边缘信息,另一路经过 DPP 池化<sup>[16]</sup>操作提取图像的空间信息,减少数据量的同时最大限度地保留原图信息。再将两个支路的结果进行融合,最后再进行二倍的下采样。

SobelConv 的结构如图 5 所示,其水平方向( $G_x$ )与垂直方向( $G_y$ )的卷积核权重定义为:

$$G_x = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix} \quad (1)$$

$$G_y = \begin{bmatrix} 1 & 0 & -1 \\ 2 & 0 & -2 \\ 1 & 0 & -1 \end{bmatrix} \quad (2)$$




图 4 ESIIM 模块

图 5 SobelConv 结构图

通过 Conv3d 层将上述卷积核扩展为三维卷积,并以分组卷积的方式独立处理每个通道的边缘特征,其中卷积核权重通过 requires\_grad = False 固定为预设值,不可学习,确保边缘提取的稳定性。最终输出边缘特征图:

$$E = \text{Conv3D}(x, G_x) + \text{Conv3D}(x, G_y) \quad (3)$$

传统池化操作(如最大池化与平均池化)在降低特征图分辨率时易导致细节丢失,本文引入细节保留池化(DPP),它是一种自适应池化方法,旨在卷积神经网络中执行下采样操作时,能够聚焦于重要的结构细节并增强网络的判别能力。它基于逆双边滤波,通过引入一个可学习的标量奖励函数来替代传统的 L2 范数计算权重,从而对每个通道独立地应用池化操作。具体而言,对于输入激活图  $I$  在空间输出位置  $p$  处的 DPP 定义为:

$$D_{\alpha, \lambda}(I)[P] = \frac{\sum_{q \in \Omega_p} [\alpha + \rho_{\lambda}(I[q] - \bar{I}[P])] \cdot I[q]}{\sum_{q' \in \Omega_p} [\alpha + \rho_{\lambda}(I[q'] - \bar{I}[P])]} \quad (4)$$

式中:  $\rho_{\lambda}(\cdot)$  为非线性奖励函数,  $\alpha$  为平滑偏置项,  $I[q]$  为输入特征图在位置  $q$  的值,  $\Omega_p$  为以  $p$  为中心结点的邻域,  $\bar{I}$  为通过线性下采样获取的局部参考值,具体来

说,首先引入一个可学习的二维滤波器  $F$ ,其大小通常为  $3 \times 3$ ,该滤波器将在特征图的局部区域内应用,以实现降采样。其次对于特征图中的每个位置  $p$ ,在其对应的局部区域  $\Omega_p$  上应用滤波器  $F$ ,计算加权求和:

$$\bar{I}[p] = \sum_{q \in \Omega_p} F[q] \cdot I[q] \quad (5)$$

为适应不同场景的需求, DPP 定义了两种奖励函数:

$$\rho_{\text{Sym}}(x) = (\sqrt{x^2 + \epsilon^2})^{\lambda} \quad (6)$$

$$\rho_{\text{Asym}}(x) = (\sqrt{\max(0, x)^2 + \epsilon^2})^{\lambda} \quad (7)$$

式(6)为对称奖励:增强输入与局部均值间的绝对差异,适用于需保留双向显著特征的任务。式(7)为非对称奖励:仅增强正向差异,模拟最大池化的特性。

传统池化操作还会出现梯度不连续的问题。由于 DPP 的操作是可微的,式(4)中平滑偏置项  $\alpha$  和奖励指数  $\lambda$  可通过反向传播优化,所以 DPP 的梯度计算基于链式法则,所有操作(包括权重归一化)支持自动微分,反向传播的梯度计算通过 PyTorch 自动微分框架实现。

ESIIM 模块通过联合边缘熵与空间熵实现对图像中高频信息(如边缘、轮廓)与低频信息(如大致纹理、结构)的有效分离与独立建模,降低了通道间的冗余与干扰。在后续融合阶段,通过加权机制和残差连接方式实现两类信息的有机组合,有助于构建更加细粒度且具备局部定位能力的特征表示。

## 2.2 C3k2-ODConv 模块

针对传统 YOLOv11 模型在复杂的工业环境中,不同铝筒之间光照不稳定、图像模糊等原因,导致关键特征信息不清晰的问题,引入 ODConv<sup>[17]</sup> 替换网络特征提取模块 C3k2 中残差块的卷积。目的是细化减震铝筒的局部细节特征。

ODConv 通过多维注意力机制自适应调整卷积核权重,从而更全面地捕捉输入特征的关键信息。解决了传统卷积无法根据输入特征动态调整权重而限制了模型表达能力的问题。ODConv 的核心思想是在卷积核的所有 4 个维度上引入动态性,其公式定义如下:

$$y = \sum_{i=1}^n (\alpha_{wi} \odot \alpha_{fi} \odot \alpha_{ci} \odot \alpha_{si} \odot W_i) * x \quad (8)$$

式中:  $W_i$  为第  $i$  个卷积核,包含  $C_{\text{out}}$  个滤波器;  $\alpha_{wi}$  为卷积核注意力,为了调整不同卷积核的权重,实现多核融合;输出通道注意力  $\alpha_{fi}$  为每个卷积滤波器的输出通道分配不同的注意力标量,增强关键特征的提取;  $\alpha_{ci}$  为输入通道注意力用于抑制冗余通道,  $\alpha_{si}$  为空间注意力,用于卷积核每个空间位置(如  $3 \times 3$  卷积核的 9 个位置)的权重,生成空间注意力图以增强重要位置的响应。全维度动态卷积实现细节如图 6 所示。




图 6 ODConv 原理图



将 ODCnv 融合进 C3k2 模块,全维度动态卷积通过并行多头注意力模块,生成 4 类互补的注意力权重,从而增加 C3k2 更细粒度的特征提取能力。

### 2.3 动态上采样器 DySample

特征上采样是密集预测模型中恢复特征分辨率的关键步骤,为了应对像检测减震铝筒这些特定的任务,考虑可学习的上采样器,但是这些采样器结构复杂计算成本高昂,不适应快节奏的工业生产环境,所以本文使用 DySample 替换 YOLOv11 颈部网络中的上采样层。

DySample 的核心思想是绕过基于核的方法,直接从点采样的角度来实现上采样,通过 PyTorch 中的内置函数 grid\_sample 来生成内容感知的采样点对连续映射进行重采样,结构如图 7 所示。




图 7 DySample 结构图

输入特征  $X$  大小为  $C \times H \times W$ ,通过线性层将输入特征转换为偏移量  $O$ ,其大小为  $2s^2 \times H \times W$ ,通过像素混洗 (Pixel Shuffle) 操作将偏移量重塑为  $2 \times sH \times sW$ ,再将偏移量  $O$  加到原来的采样网格  $G$  上,得到采样集  $S$ ,最后使用 grid\_sample 函数对输入特征  $X$  进行重采样,生成上采样后的特征图  $X'$ 。在采样点生成器的过程中,偏移量  $O$  的采样因子改为逐点动态范围因子,其值域在  $[0, 0.5]$  之间,公式为:

$$O = 0.5\sigma(\text{linear}_1(X)) \cdot \text{linear}_2(X) \quad (9)$$

式中:  $\sigma$  为 Sigmoid 函数,用于生成动态范围因子。

DySample 相比其他基于核的动态上采样器,拥有更少的参数和更低的浮点运算次数,节省了计算资源,更加有利于工业实时检测。其独特的点采样方式能够在多尺度下捕捉减震铝筒的细节特征。

### 2.4 CGAFusion 特征融合模块

在检测减震铝筒的过程中,不同减震铝筒相异特征在图像中所占的像素格较少,难以找到足够判断其相异性的特征,且随着后期卷积越来越多,这些相异性特征丢失的也就越多。为了解决上述问题,在检测头之前,使用 CGAFusion 特征融合模块将颈部网络的特征提取层与主干




图 8 CGAFusion 结构图

网络的特征提取层进行融合。模块结构如图 8 所示。

首先,将浅层特征  $F_{low}$  和深层特征  $F_{high}$ ,生成通道特定的空间权重  $W$ :

$$W = CGA([F_{low}, F_{high}]) \quad (10)$$

其中,CGA 通过粗粒度 SIM 生成(通道注意力+空间注意力)与内容引导细化(通道混洗+分组卷积)动态调整权重。每个通道的权重  $W$  独立生成,适应不同通道的特征分布,比如某些通道关注减震铝筒的边缘,某些通道关注图像的明暗程度。最后采用加权求和方式融合特征,并加入残差连接以缓解梯度消失:

$$F_{fuse} = C_{1 \times 1}(F_{low} \cdot W + F_{high} \cdot (1-W) + F_{low} + F_{high}) \quad (11)$$

式中:  $C_{1 \times 1}$  为  $1 \times 1$  卷积,用于调整融合后的通道维度;  $W$  与  $(1-W)$  分别为调制低层与高层特征的贡献,实现自适应混合;残差项  $F_{low} + F_{high}$  用于保留原始特征信息,增强训练稳定性。

## 3 实验结果与分析

### 3.1 减震铝筒数据集与实验参数

本文的研究使用自制的数据集,通过海康相机对 5 种减震铝筒进行拍摄,包括不同摆放方式、不同光照强度,共计 2340 张图片,尺寸为 640 像素  $\times$  640 像素,使用 LableImg 对图片进行标注,分为 A 型、B 型、C 型、D 型、E 型铝筒,按 7:1:2 的比例将数据集分为训练集、验证集和测试集。

本文的所有实验是基于 Windows11 操作系统下进行的,CPU 型号为 AMD Ryzen 9 7945HX;GPU 型号为 NVIDIA GeForce RTX 4060(8 G);系统内存为 16 G。实验环境使用 Python3. 10. 15、Pytorch2. 2. 1 和 Cuda12. 1 深度学习框架对模型进行训练。

设置训练轮数 (epochs) 为 750 轮,批量大小 (batch size) 为 32。采用 SGD 优化器,初始学习率为 0. 01,动量因子为 0. 937,权重衰减系数为 0. 000 5。

本文算法使用的损失函数由边界框回归损失 (box loss)、分类损失 (classification loss) 和分布式焦点损失 (distribution focal loss, DFL) 组成,权重分别为 7. 5、0. 5 和 1. 5。

### 3.2 评价指标

为了对改进后的 YOLOv11 进行评价和实验,采用的评价指标主要有精度 (P)、召回率 (R)、多类别平均精度 (mAP@0. 5:0. 95)、每秒帧率 (FPS),其中 mAP@0. 5:0. 95 表示检测框交并比为 0. 5 ~ 0. 95 的平均精度,这些评价指标的公式分别如式 (12) ~ 式 (15) 所示。

$$P = \frac{TP}{TP + FP} \quad (12)$$

$$R = \frac{TP}{TP + FN} \quad (13)$$

$$mAP = \frac{\sum_{i=1}^N \int_0^1 P_i(R_i) d(R_i)}{N} \quad (14)$$

$$FPS = \frac{1}{PRT + INT + POT} \quad (15)$$

式中:  $TP$  为真阳性,  $FP$  为假阳性,  $FN$  为假阴性,  $N$  为

检测目标种类的数量, $PRT$  为预处理时间, $INT$  为推理时间, $POT$  为后处理时间。

3.3 消融实验

为了验证 4 种改进方法对模型的提升效果,在自制的数据集上进行消融实验,如表 1 所示。实验结果表明,4 个改进模块依次加入到基础模块中时,模型对减震铝筒的检测性能逐步提高。首先在主干网络之前加入边缘与空间信息整合模块后, $mAP@0.5:0.95$  提升 0.9%,这表明网络的输入端加入边缘信息后有效缓解了网络提取特征不全的问题,增加了网络对高相似度铝筒的识别能力,模块中的空间信息提取部分使用细节保留池化 DPP,保留细节的同时还能降低参数,减少计算量,所以 GFLOPS 只增加了 0.4。接着使用 ODConv 替换 C3k2 瓶颈结构中的卷积,使得  $mAP@0.5:0.95$  提升 1.3%,这表明 ODConv 多通道的注意力权重增加了 C3k2 更细粒度的特征提取能力,进一步增强了对减震铝筒的识别能力。其次,将颈部网络中的上采样用动态上采样 DySample 替换,  $mAP@0.5:0.95$  提升了 0.5%,这表明 DySample 点采样策略更适合恢复减震铝筒的特征分辨率,提升了模型的检测能力。最后加入 CGAFusion 特征融合模块,又使得  $mAP$  提升了 1.4%,说明低层特征与高层特征的融合可以解决细节特征丢失的问题,尽管 GFLOPS 提升了很多,但是 CGAFusion 对模型性能的提升最大,而且 FPS 依旧很高,能够满足实际的工业需求。

表 1 消融实验

| YOLOv11   | ESIM   | C3k2-ODConv       | DySample |
|-----------|--------|-------------------|----------|
| ✓         |        |                   |          |
| ✓         | ✓      |                   |          |
| ✓         | ✓      | ✓                 |          |
| ✓         | ✓      | ✓                 | ✓        |
| ✓         | ✓      | ✓                 | ✓        |
| CGAFusion | GFLOPS | $mAP@0.5:0.95/\%$ | FPS      |
|           | 6.3    | 0.862             | 289      |
|           | 6.7    | 0.871             | 262      |
|           | 5.7    | 0.884             | 342      |
|           | 5.8    | 0.889             | 296      |
| ✓         | 7.8    | 0.903             | 217      |

3.4 对比实验

为了验证本文模型在减震铝筒检测过程中的优越性,本文将改进后的模型和当前主流模型在自制的数据集上进行对比试验,实验时保证所有的超参都相同,尽量控制变量,实验结果如表 2 所示。

表 2 对比实验

| 模型          | GFLOPS | $mAP@0.5:0.95/\%$ | FPS |
|-------------|--------|-------------------|-----|
| Faster-RCNN | 180    | 87.6              | 19  |
| SSD         | 68     | 81.2              | 66  |
| YOLOv3-Tiny | 5.6    | 79.1              | 52  |
| YOLOv5      | 7.2    | 87.7              | 183 |
| YOLOv8n     | 8.9    | 88.6              | 234 |
| YOLOv10     | 6.7    | 85.3              | 177 |
| YOLOv11n    | 6.3    | 86.2              | 289 |
| ours        | 7.8    | 90.3              | 217 |

考虑到工厂对减震铝筒漏检率有较高的要求,算法的精度要尽可能地高,同时保证一定的 FPS 以满足车间快速的生产节奏。从表 2 可以看出,两阶段算法 FPS 过低,不满足实际工业生产对实时检测的需求。本文算法与其他 YOLO 算法比较发现,平均精度皆高于其他算法,虽然 FPS 略低,但是依然能满足算法实时性检测的需求。

3.5 可视化实验结果分析

为了可视化地展现改进后的模型对减震铝筒检测的性能,将 YOLOv11n 与本文的算法比较,其相关参数的对比曲线图如图 9 所示,可以看出改进后的算法相比于原来的模型准确度提升 0.4%、召回率提升 0.9%、 $mAP@0.5$  提升 0.8%、 $mAP@0.5:0.95$  提升 4.1%。表明改进后的算法相比于原算法更加可靠。




图 9 改进效果对比图

最后,将 YOLOv11n 与本文的算法在同一个测试集下进行推理,测试集包含了多种工况的图像(如:光线不稳定、图像模糊、减震铝筒高度相似),两种算法推理的对比图如图 10 所示,从图中可以看出改进前的模型有错检的现象,特别是相似度最高的 B 型和 C 型铝筒,在 470 张测试集中出现这些现象的概率为 8.51%,而改进后的模型在同样的测试集中出现错检的概率为 2.98%,降低了 5.53%。




图 10 推理结果对比图

4 结论

本文针对复杂工业环境下减震铝筒检测存在的挑

战,提出了一种改进的 YOLOv11n 模型。通过引入 ESIIM 边缘与空间信息整合模块、ODConv 全维度动态卷积、DySample 动态上采样器及 CGAFusion 特征融合模块,模型在特征提取、细节增强和特征融合方面取得了显著提升。实验结果表明,改进后模型的 mAP@0.5:0.95 达到 90.3%,较基准模型提升 4.1%,同时错检率降低 5.53%,在保持实时检测效率(217 FPS)的前提下,显著提升了检测精度与鲁棒性。该研究为工业场景下高相似度工件的精准识别提供了有效解决方案,未来可进一步优化计算效率,并探索其在其他复杂工业检测任务中的适用性。

#### [参考文献]

- [1] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//2014 IEEE Conference on Computer Vision and Pattern Recognition, 2014:580-587.
- [2] GIRSHICK R. Fast R-CNN[J]. CoRR, 2015, abs/1504.08083.
- [3] REN S Q, HE K M, GIRSHICK R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6):1137-1149.
- [4] HE K M, GKIOXARI G, DOLLÁR P, et al. Mask R-CNN[C]//2017 IEEE International Conference on Computer Vision (ICCV), 2017:2980-2988.
- [5] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: unified, real-time object detection[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016:779-788.
- [6] REDMON J, FARHADI A. YOLOv3: an incremental improvement[EB/OL]. 2018; arXiv: 1804. 02767. <https://arxiv.org/abs/1804.02767>.
- [7] BOCHKOVSKIY A, WANG C Y, LIAO H M. YOLOv4: optimal speed and accuracy of object detection[EB/OL]. 2020; arXiv: 2004. 10934. <https://arxiv.org/abs/2004.10934>.
- [8] GE Z, LIU S T, WANG F, et al. YOLOx: exceeding YOLO series in 2021[EB/OL]. 2021; arXiv: 2107. 08430. <https://arxiv.org/abs/2107.08430>.
- [9] 程光耀, 张文强, 王志城, 等. 改进 YOLOv5s 的地铁齿轮箱螺丝状态检测[J]. 计算机工程与应用, 2025, 61(20): 358-367.
- [10] 朱晓彤, 张荣芬, 刘宇红, 等. Dim-YOLOv5n 昏暗场景目标检测算法[J]. 计算机工程与应用, 2024, 60(11): 173-181.
- [11] 季星宇, 黄陈蓉, 姚军财, 等. 结合分支特征和排斥损失的绝缘子检测研究[J]. 计算机工程与应用, 2025, 61(7): 141-152.
- [12] WANG Y, ZENG W G, XU H Q, et al. Multi-type ship target detection in complex marine background based on YOLOv11[J]. Processes, 2025, 13(1): 249.
- [13] 李彬, 李生林. 改进 YOLOv11n 的无人机小目标检测算法[J]. 计算机工程与应用, 2025, 61(7): 96-104.
- [14] KHANAM R, HUSSAIN M. YOLOv11: an overview of the key architectural enhancements[EB/OL]. 2024; arXiv: 2410. 17725. <https://arxiv.org/abs/2410.17725>.
- [15] 郭宏, 畅晨吕, 张德华, 等. 基于改进 YOLOv5 算法的堆叠工件检测方法[J]. 组合机床与自动化加工技术, 2024(10): 109-114.
- [16] SAEEDAN F, WEBER N, GOESELE M, et al. Detail-preserving pooling in deep networks[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018:9108-9116.
- [17] LI C, ZHOU A J, YAO A B. Omni-dimensional dynamic convolution[EB/OL]. 2022; arXiv: 2209. 07947. <https://arxiv.org/abs/2209.07947>. (编辑 赵 蓉)
- [8] CHE Z Y, PENG C, LIAO T W, et al. Improving milling tool wear prediction through a hybrid NCA-SMA-GRU deep learning model[J]. Expert Systems with Applications, 2024, 255: 124556.
- [9] LIU X L, LIU S Y, LI X B, et al. Intelligent tool wear monitoring based on parallel residual and stacked bidirectional long short-term memory network[J]. Journal of Manufacturing Systems, 2021, 60: 608-619.
- [10] LIU H, LIU Z Y, JIA W Q, et al. A novel transformer-based neural network model for tool wear estimation[J]. Measurement Science and Technology, 2020, 31(6): 065106.
- [11] VON HAHN T, MECHEFSKE C K. Self-supervised learning for tool wear monitoring with a disentangled-variational-autoencoder[J]. International Journal of Hydromechatronics, 2021, 4(1): 69-98.
- [12] YAN S, SHAO H D, XIAO Y M, et al. Hybrid robust convolutional autoencoder for unsupervised anomaly detection of machine tools under noises[J]. Robotics and Computer-Integrated Manufacturing, 2023, 79: 102441.
- [13] MA J, WANG X Y, LV Y Y, et al. Fault prediction of non-linear multi-mode industrial process based onMKP-CAModel[J]. The Canadian Journal of Chemical Engineering, 2023, 101(5): 2556-2565.
- [14] GONG D, LIU L Q, LE V, et al. Memorizing normality to detect anomaly: memory-augmented deep autoencoder for unsupervised anomaly detection[C]//2019 IEEE/CVF International Conference on Computer Vision (ICCV), 2020: 1705-1714.
- [15] WANG X H, DU Y, LIN S J, et al. adVAE: a self-adversarial variational autoencoder with Gaussian anomaly prior knowledge for anomaly detection[J]. Knowledge-Based Systems, 2020, 190: 105187.
- [16] YU J B, ZHOU X K. One-dimensional residual convolutional autoencoder based feature learning for gearbox fault diagnosis[J]. IEEE Transactions on Industrial Informatics, 2020, 16(10): 6347-6358.
- [17] WU J Y, ZHAO Z B, SUN C, et al. Fault-attention generative probabilistic adversarial autoencoder for machine anomaly detection[J]. IEEE Transactions on Industrial Informatics, 2020, 16(12): 7479-7488.
- [18] DEWANGAN G, MAURYA S. Fault diagnosis of machines using deep convolutional beta-variational autoencoder[J]. IEEE Transactions on Artificial Intelligence, 2022, 3(2): 287-296.
- [19] JIANG J S, REN H R, ZHANG M. A convolutional autoencoder method for simultaneous seismic data reconstruction and denoising[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 1-5. (编辑 祝智铭)

(上接第 40 页)